




Flujo de MLOps: Movimiento de Datos y Artefactos





Fase 1 — Model Handover (Entrega)

Qué es


Formalizar código experimental en un artefacto reproducible.

Acciones

Empaquetar código de entrenamiento, hiperparámetros y entorno (Docker, requirements.txt).

Objetivo

Pasar de "funciona en mi laptop" a un paquete cerrado que garantiza reproducibilidad.



Fase 2 — CI: ML Pipeline (Integración Continua)


Push Code

Run Tests

Validate Schema


Controlled Train

Al hacer push, la CI ejecuta pruebas de código y validaciones de datos; valida que el entrenamiento sea reproducible en entorno controlado antes de promover artefactos.



Fase 3 — Artifact Storage (Almacenamiento)

- Inventario central de versiones aprobadas (model.pkl / model.onnx, Docker images).
- Metadatos: métricas, lineage, hash de código y condiciones de entrenamiento.
- Regla de oro: nada a producción sin registro y versionado (ej. v1.0 → v1.1).



Fase 4 — CD: ML Pipeline (Despliegue Continuo)

Automatización que transporte artefactos desde storage a entornos reales: re-entrenamiento programado o despliegue para predicción. Resultado: infraestructura aprovisionada (Kubernetes) y servicio modelo listo para consumo.

- Dos rutas: pipeline de re-entrenamiento vs. servicio de inferencia. Ambas requieren validaciones previas y control de versiones.

Stack Tecnológico — Herramientas



Handover → CI

GitHub Actions +
MLflow: scripts de
entrenamiento,
tracking de
experimentos y
reproducibilidad.



CI → Storage

Jenkins + Amazon
S3: orquestación de
jobs y
almacenamiento
versionado de
artefactos
(.pkl/.onnx).



Storage → CD

Argo CD: observa
repositorios y aplica
actualizaciones
declarativas al
clúster.



CD → Producción

Kubernetes:
orquestación,
escalado y gestión
del ciclo de vida del
servicio de
inferencia.

Gestión de Riesgos y Fallos

Inconsistencia de entorno

Solución: Dockerización estricta — distribuir imágenes congeladas, no solo código.

Regresión de calidad

Solución: Quality Gates — comparar métricas automáticamente contra producción antes de promover.

Modelos huérfanos

Solución: Metadata logging automático que vincule ID de artefacto con SHA de Git y experimento MLflow.



Seguridad operativa: rollback automático si falta integridad (checksums, firmas, tests de humo) y alertas a pipeline de observabilidad.

Resumen del Flujo Lógico

01

Handover

"Paquete terminado" — artefacto reproducible con entorno y metadatos.

02

CI

¿Código y datos funcionan juntos? Pruebas, validaciones y ejecución controlada de entrenamiento.

03

Storage

Guardar versión aprobada en bodega con metadata y lineage.

04

CD

Transportar de bodega a producción — despliegue automatizado y monitoreado.

Implementar este flujo reduce fricción entre equipos, mejora reproducibilidad y crea rutas claras para rollback y gobernanza.

